

PROJETO DE CREDIT SCORING - QUANTUM FINANCE

MBA em Data Science & Artificial Intelligence - Applied Statistics

CONTEXTO EMPRESARIAL

A **Quantum Finance** é uma fintech inovadora que está entrando no mercado financeiro para competir com grandes players estabelecidos. Como parte de sua estratégia de crescimento sustentável, a empresa está enfrentando um crescimento preocupante na taxa de inadimplência entre seus clientes atuais.

Para tomar decisões mais precisas sobre concessões de crédito e atrair novos clientes com perfil de baixo risco, a Quantum Finance precisa desenvolver um modelo robusto de **Credit Scoring** utilizando técnicas avançadas de ciência de dados e machine learning.

OBJETIVO DO PROJETO

Desenvolver um modelo preditivo de credit scoring utilizando regressão linear múltipla para prever o **SCORE_CREDITO** dos clientes, permitindo à Quantum Finance tomar decisões mais assertivas na concessão de crédito e reduzir significativamente a taxa de inadimplência.

DATASET DISPONÍVEL

O dataset ``Base_ScoreCredito_QuantumFinance.csv`` contém **10.128 registros** de clientes com as seguintes variáveis:

Variáveis Demográficas:

- **id**: Identificador único do cliente
- **idade**: Idade em anos
- **sexo**: Gênero (F = Feminino, M = Masculino)
- **estado_civil**: Estado civil (Solteiro, Casado, Divorciado)
- **escola**: Nível de escolaridade (ensino fundam, ensino médio, graduação, mestrado, doutorado)
- **Qte_dependentes**: Quantidade de dependentes

Variáveis Profissionais e Financeiras:

- **tempo_ultimoservico**: Tempo no último emprego (meses)
- **trabalha**: Situação atual de trabalho (0=Não, 1=Sim)

- **vl_salario_mil**: Salário em milhares de reais

Variáveis Patrimoniais:

- **reg_moradia**: Região da moradia (1 a 6 - segmentos geográficos A a F)
- **casa_propria**: Possui casa própria (0=Não, 1=Sim)
- **vl_imovel_em_mil**: Valor do imóvel em milhares de reais
- **Qte_cartoes**: Quantidade de cartões de crédito
- **Qte_carros**: Quantidade de carros

Variável Target:

- **SCORE_CREDITO**: Score de crédito (variável dependente a ser predita)

ETAPAS DO PROJETO

1. ANÁLISE EXPLORATÓRIA DE DADOS (EDA)

1.1 Análise Descritiva Univariada

- Calcular estatísticas descritivas para todas as variáveis numéricas (média, mediana, desvio padrão, quartis, valores mínimos e máximos)
- Analisar a distribuição da variável target `SCORE\_CREDITO` através de histogramas e boxplots
- Verificar a presença de outliers em todas as variáveis numéricas
- Analisar a distribuição de frequências das variáveis categóricas

1.2 Análise de Dados Faltantes

- Identificar padrões de missing values em todas as variáveis
- Calcular percentual de dados faltantes por variável
- Decidir estratégias de tratamento (imputação, remoção, etc.)

1.3 Visualizações Gráficas

- Criar histogramas e boxplots para variáveis numéricas
- Criar gráficos de barras para variáveis categóricas
- Analisar a distribuição da variável target por diferentes segmentos

2. TESTE DE HIPÓTESE E INTERVALO DE CONFIANÇA

2.1 Teste de Hipótese para Diferença de Médias

Realizar teste t para comparar o score de crédito médio entre dois grupos:

Hipótese a ser testada:

- $H_0: \mu_1 = \mu_2$ (Não há diferença significativa no score de crédito médio entre clientes que

possuem casa própria e os que não possuem)

- $H_1: \mu_1 \neq \mu_2$ (Há diferença significativa no score de crédito médio entre os grupos)

****Procedimento:****

- Aplicar teste de normalidade (Shapiro-Wilk ou Kolmogorov-Smirnov)
- Realizar teste t independente ou Mann-Whitney (caso não haja normalidade)
- Definir nível de significância $\alpha = 0,05$
- Interpretar o p-valor e tomar decisão sobre as hipóteses

2.2 Intervalo de Confiança

Calcular o intervalo de confiança de 95% para a média do score de crédito da população, interpretando os resultados no contexto do negócio.

3. ANÁLISE DE CORRELAÇÃO

3.1 Matrix de Correlação

- Calcular correlação de Pearson entre todas as variáveis numéricas
- Criar heatmap da matriz de correlação
- Identificar variáveis com alta correlação ($|r| > 0,7$) para detectar possível multicolinearidade

3.2 Análise de Associação

- Investigar relação entre variáveis categóricas e o score de crédito
- Realizar ANOVA para testar diferenças de médias entre grupos
- Criar boxplots para visualizar relações

4. PRÉ-PROCESSAMENTO DOS DADOS

4.1 Tratamento de Dados Faltantes

- Implementar estratégias de imputação baseadas na análise exploratória
- Documentar todas as decisões tomadas

4.2 Tratamento de Outliers

- Identificar outliers usando método IQR ou Z-score
- Decidir sobre remoção, transformação ou manutenção dos outliers
- Justificar decisões baseando-se no contexto do negócio

4.3 Codificação de Variáveis Categóricas

- Aplicar One-Hot Encoding ou Label Encoding conforme apropriado
- Tratar a variável `estado\_civil` que contém valores "na"

4.4 Normalização/Padronização

- Avaliar necessidade de normalização das variáveis numéricas
- Aplicar técnicas apropriadas se necessário

4.5 Divisão dos Dados

- Dividir dataset em treino (70%) e teste (30%)
- Utilizar stratified split se necessário
- Definir random_state para reprodutibilidade

5. MODELAGEM

5.1 Modelo de Regressão Linear Múltipla

- Implementar modelo de regressão linear múltipla usando todas as variáveis
- Verificar significância estatística dos coeficientes
- Interpretar coeficientes no contexto do negócio

5.2 Seleção de Variáveis

- Aplicar métodos de seleção de features:
 - Forward Selection
 - Backward Elimination
 - Stepwise Selection
- Comparar modelos com diferentes conjuntos de variáveis

5.3 Validação das Suposições do Modelo

- **Linearidade**: Analisar scatter plots de variáveis vs. target
- **Independência**: Verificar independência dos resíduos
- **Homocedasticidade**: Testar homogeneidade da variância dos resíduos
- **Normalidade dos resíduos**: Aplicar testes de normalidade e Q-Q plots
- **Ausência de multicolinearidade**: Calcular VIF (Variance Inflation Factor)

6. ANÁLISE DE RESÍDUOS

6.1 Diagnóstico dos Resíduos

- Criar gráficos de resíduos vs. valores preditos
- Analisar normalidade dos resíduos com histogramas e Q-Q plots
- Identificar padrões que violem as suposições do modelo
- Detectar outliers e pontos de alta alavancagem

6.2 Testes Estatísticos

- Teste de Breusch-Pagan para homocedasticidade
- Teste de Durbin-Watson para autocorrelação
- Teste de normalidade dos resíduos

7. MÉTRICAS DE AVALIAÇÃO

7.1 Métricas de Regressão

- **MAE (Mean Absolute Error)**: Erro médio absoluto
- **MSE (Mean Squared Error)**: Erro quadrático médio
- **RMSE (Root Mean Squared Error)**: Raiz do erro quadrático médio
- **R² (Coeficiente de Determinação)**: Porcentagem da variância explicada
- **R² Ajustado**: R² penalizado pelo número de variáveis

7.2 Análise de Performance

- Comparar métricas entre conjunto de treino e teste
- Avaliar se há overfitting ou underfitting
- Criar gráficos de valores reais vs. preditos

7.3 Validação Cruzada

- Implementar k-fold cross-validation (k=5)
- Calcular média e desvio padrão das métricas
- Avaliar estabilidade do modelo

8. INTERPRETAÇÃO E CONCLUSÕES

8.1 Interpretação dos Coeficientes

- Explicar o impacto de cada variável no score de crédito
- Identificar as variáveis mais importantes para o modelo
- Contextualizar resultados para o negócio da Quantum Finance

8.2 Recomendações de Negócio

- Sugerir estratégias para melhoria do modelo
- Recomendar variáveis adicionais que poderiam ser coletadas
- Propor limites de score para decisões de crédito

ENTREGÁVEIS

1. Arquivo Word com Resultados e Interpretações

O documento deve conter:

Quadro Conceitual Estatístico

Preencher a tabela com os seguintes componentes:

- **Tema**: Desenvolvimento de modelo de credit scoring
- **Problema**: [Definir problema específico]
- **Hipóteses conceituais**: [Elaborar hipóteses do estudo]
- **Objetivo principal**: [Objetivo específico do modelo]
- **População de estudo**: [Definir população-alvo]

- ****Plano básico de análise****: [Estratégia de análise]
- ****Técnica estatística****: Regressão Linear Múltipla
- ****Resultado principal****: [Resultado esperado]

Análises Obrigatórias:

- ****Análise descritiva das variáveis****: Estatísticas resumo e visualizações
- ****Análise de correlação das variáveis****: Matriz de correlação e interpretações
- ****Análise de resíduos****: Gráficos e testes diagnósticos
- ****Acurácia e medidas de erros do modelo****: Todas as métricas calculadas

Recomendações Críticas:

Responder obrigatoriamente:

- ****As variáveis são suficientes para tomada de decisão?****
 - Análise da capacidade preditiva do modelo
 - Sugestões de variáveis adicionais
 - Limitações identificadas
- ****As suposições do modelo de regressão linear múltipla foram atendidas?****
 - Verificação de cada suposição
 - Impacto das violações encontradas
 - Sugestões de melhorias ou modelos alternativos

2. Script Python Completo

- Código comentado com todas as análises
- Estrutura organizada e reproduzível
- Documentação clara de cada etapa
- Visualizações de alta qualidade

CRITÉRIOS DE AVALIAÇÃO

Técnicos (70%)

- Correção metodológica das análises estatísticas
- Qualidade do pré-processamento dos dados
- Adequação das técnicas de modelagem
- Interpretação correta dos resultados

Negócio (30%)

- Contextualização dos resultados para a Quantum Finance
- Qualidade das recomendações estratégicas
- Viabilidade das sugestões propostas

RECURSOS NECESSÁRIOS

Bibliotecas Python Recomendadas:

- `pandas`, `numpy`: Manipulação de dados
- `matplotlib`, `seaborn`: Visualizações
- `scikit-learn`: Modelagem e métricas
- `scipy`, `statsmodels`: Testes estatísticos e regressão
- `warnings`: Controle de avisos

Referências Bibliográficas:

- James, G. et al. "An Introduction to Statistical Learning"
- Hastie, T. et al. "The Elements of Statistical Learning"
- Documentação oficial do scikit-learn

****Data de Entrega**:** [Definir data]

****Formato de Entrega**:** Arquivo Word + Script Python (.py ou .ipynb)

Este projeto simula um desafio real de uma fintech, desenvolvendo competências essenciais em ciência de dados aplicada ao setor financeiro.